

Unidad didáctica

Del dato público a una conclusión analítica reproducible

Responsible Gambling Analytics — mercado online español

Resumen del Proyecto

El ejercicio permite recorrer el ciclo completo de un proyecto analítico. No se utiliza como un ejercicio para obtener un p-valor, sino para enseñar que una conclusión fiable depende de toda la cadena: fuente, contrato, calidad, transformación, diseño estadístico, validación y comunicación.

Caso práctico: Evolución de la intensidad agregada del juego online en España con datos públicos de la DGOJ.

Nivel: Bootcamp de Data Analytics, nivel intermedio con ampliaciones avanzadas.

Duración base: 8 horas (4 sesiones de 2 horas).

1 Ficha de la unidad

Título	Del dato público a una conclusión analítica reproducible
Caso práctico	Evolución de la intensidad agregada del juego online en España con datos públicos de la DGOJ
Nivel	Bootcamp de Data Analytics, nivel intermedio con ampliaciones avanzadas
Duración base	8 horas: 4 sesiones de 2 horas
Ampliación	2 horas para desestacionalización, control estadístico de procesos y validación temporal avanzada
Modalidad	Taller práctico con explicación, ejecución guiada, análisis en grupos y defensa final
Herramientas	Python 3.14, PowerShell, entorno virtual, pandas, DuckDB, SciPy, Matplotlib, Jupyter y pytest
Unidad de análisis	Mercado español agregado por trimestre; no representa personas ni cuentas individuales
Producto final	Pipeline reproducido, notebook ejecutado, interpretación estadística y breve informe diferenciado por perfil profesional

Pregunta vertebradora

¿Existe un cambio relevante en la intensidad agregada del juego online a partir de 2020-T2 y qué evidencia sería necesaria para distinguir una ruptura asociada al COVID-19 de la tendencia estructural previa?

La pregunta está formulada deliberadamente en dos niveles:

1. **Descriptivo:** comprobar si los indicadores cambian alrededor de 2020-T2.
2. **Causal:** evaluar si los datos permiten atribuir ese cambio al confinamiento.

El primer nivel sí puede abordarse con este proyecto. El segundo no queda resuelto mediante una comparación simple antes/después.

2 Justificación pedagógica

El ejercicio permite recorrer el ciclo completo de un proyecto analítico, estructurado de la siguiente forma:

1. Fuente web DGOJ
2. Extracción y manifiesto
3. Perfilado y contrato de datos
4. Transformación trimestral
5. DuckDB y consultas SQL
6. EDA y series temporales
7. Contraste e interpretación
8. Decisión y límites

También permite diferenciar tres formas de trabajar con el mismo dato:

- **BI/Product Analytics:** convierte datos fiables en métricas, tendencias y decisiones de negocio.
- **Data Engineering Analytics:** garantiza que la información llega completa, consistente, trazable y repetible.
- **Data Science:** formaliza hipótesis, cuantifica incertidumbre y evalúa explicaciones alternativas.

3 Resultados de aprendizaje

Al finalizar la unidad, el alumnado será capaz de:

- Explicar la diferencia entre repetibilidad, reproducibilidad e idempotencia.
- Identificar por qué una extracción web necesita un contrato verificable con la fuente.
- Ejecutar el proyecto dentro de un entorno virtual y justificar su utilidad.
- Distinguir pruebas unitarias, de componente, de integración y de contrato.
- Realizar un EDA orientado a preguntas, no una colección indiscriminada de gráficos.
- Identificar granularidad, claves, métricas aditivas y no aditivas.
- Formular una hipótesis nula y una alternativa antes de observar el resultado.
- Diferenciar asociación temporal, correlación espuria y causalidad.
- Visualizar series temporales evitando ejes y agregaciones engañosas.
- Explicar por qué dos series con tendencia pueden mostrar una correlación artificialmente elevada.
- Aplicar técnicas básicas de desestacionalización y eliminación de tendencia.
- Comprender el propósito del control estadístico de procesos y sus límites en series no estacionarias.
- Aplicar e interpretar el contraste U de Mann–Whitney.
- Diferenciar error de tipo I, error de tipo II, significancia estadística y relevancia práctica.
- Comunicar una conclusión adecuada para BI, Data Engineering o Data Science.

4 Conocimientos previos

4.1 Obligatorios

- Conceptos básicos de tablas, filas, columnas y tipos de datos.
- Operaciones SQL sencillas: `SELECT`, `WHERE`, `GROUP BY` y `JOIN`.
- Uso elemental de Python o capacidad para seguir un notebook guiado.
- Estadística descriptiva: media, mediana, percentiles y dispersión.

4.2 Recomendados

- pandas y Matplotlib.
- Concepto de función y prueba automatizada.
- Probabilidad elemental.
- Interpretación básica de series temporales.

No se presupone experiencia previa con DuckDB, pytest, pruebas de contrato ni control estadístico de procesos.

5 Clasificación del conocimiento por perfil

5.1 Escala de dominio

Nivel	Significado
N0 — Reconocer	Entender el concepto y detectar cuándo es relevante.
N1 — Aplicar con guía	Ejecutar un procedimiento existente e interpretar su salida.
N2 — Trabajar con autonomía	Diseñar, implementar y justificar la solución habitual.
N3 — Diseñar y revisar	Seleccionar métodos, anticipar fallos y revisar críticamente soluciones ajenas.

6 El caso y sus datos

El proyecto utiliza cuatro series públicas de la DGOJ:

Fuente	Grano original	Contenido principal
<code>ggr_turnover.csv</code>	Mes $\times$ modalidad	Cantidades jugadas y GGR de 17 modalidades
<code>deposits_withdrawals.csv</code>	Mes	Depósitos, retiradas y número de depósitos reportado
<code>accounts.csv</code>	Mes	Cuentas activas y nuevas
<code>marketing.csv</code>	Mes	Publicidad, bonos, afiliados, patrocinio y total promocional

Cobertura de la copia congelada: enero de 2013 a septiembre de 2025, equivalente a 153 meses o 51 trimestres.

6.1 Hallazgos de calidad que condicionan el análisis

- No hay huecos mensuales ni duplicados de clave en las cuatro fuentes.
- `ggr_turnover` contiene 2.601 filas: 17 modalidades $\times$ 153 meses.
- Existen 88 valores mensuales de GGR negativo. No deben borrarse automáticamente: pueden representar premios superiores a las cantidades jugadas en una modalidad y mes.
- `Nº de depósitos` vale cero desde enero de 2018. Es una métrica descontinuada, no evidencia de que no existieran depósitos.

- Las cuentas activas son una fotografía mensual: deben promediarse al construir el trimestre, no sumarse.
- Depósitos, retiradas, GGR, marketing y cuentas nuevas son flujos: se suman al agregar los tres meses de un trimestre.

Este bloque enseña una regla esencial: **el significado de negocio determina la agregación; el tipo numérico de la columna no lo hace.**

7 Repetibilidad, reproducibilidad e idempotencia

7.1 Repetibilidad

Un proceso es repetible cuando la misma persona, en el mismo entorno, utilizando los mismos datos y el mismo código, obtiene el mismo resultado. Ejemplo:

```
python -m src.transform
python -m src.build_database
python -m pytest -q
```

7.2 Reproducibilidad

Un proceso es reproducible cuando otra persona puede reconstruir el resultado en otro equipo a partir de instrucciones, código, datos o referencias de origen, versiones y decisiones documentadas.

7.3 Idempotencia

Una operación es idempotente cuando repetirla no produce efectos acumulativos incorrectos (ej. reconstruir tablas de DuckDB no debe duplicar filas).

8 Contract testing para una fuente web

Un contrato expresa las condiciones mínimas que el proveedor y el consumidor esperan mantener. Una validación de esquema comprueba un archivo que ya tenemos, mientras que un **contract test** comprueba que la interacción con la fuente externa sigue satisfaciendo las expectativas del consumidor.

Estrategia de ejecución recomendada:

- Unitarios: en cada cambio.
- Componente: en cada cambio relevante.
- Contrato: diariamente, semanalmente o antes de una actualización de datos.
- Integración completa: antes de una entrega o publicación.

9 Entornos virtuales

Un entorno virtual es un directorio que contiene un intérprete de Python y un conjunto aislado de paquetes para un proyecto. Aísla dependencias, versiones y scripts.

```
py -3.14 -m venv .venv
.\.venv\Scripts\Activate.ps1
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
```

10 Tipos de pruebas

- **Prueba unitaria:** Verifica una función de forma aislada sin red.
- **Prueba de componente:** Verifica un componente completo con dependencias controladas.
- **Prueba de integración:** Comprueba la interacción entre varios componentes reales.
- **Prueba de contrato:** Comprueba el acuerdo observable en el límite entre sistemas.

11 Formulación de hipótesis

Observación: *En el gráfico aparece un salto en la intensidad alrededor de 2020-T2.*

Definición previa de grupos:

- **Pre:** 2013-T1 a 2019-T4, 28 trimestres.
- **Transición excluida:** 2020-T1, porque el confinamiento comenzó a mitad del trimestre.
- **Post:** 2020-T2 a 2025-T3, 22 trimestres.

Hipótesis nula y alternativa bilateral:

$$H_0 : F_{pre}(x) = F_{post}(x)$$

$$H_1 : F_{pre}(x) \neq F_{post}(x)$$

Advertencia Causal

El contraste pre/post no identifica efecto causal porque mezcla tendencia previa, estacionalidad, marketing, y otros cambios económicos.

12 Correlación entre series temporales

12.1 Por qué la correlación convencional puede fallar

Pearson o Spearman sobre dos series crecientes pueden producir una relación alta aunque sus innovaciones no estén relacionadas.

12.2 Secuencia recomendada

1. Graficar ambas series en nivel.
2. Transformar a logaritmo si la variabilidad crece con el nivel.
3. Eliminar tendencia.
4. Eliminar estacionalidad.
5. Revisar autocorrelación de los residuos.
6. Calcular correlación o correlación cruzada sobre componentes comparables.

Ejemplo de diferenciación en Python:

```
df["delta_1"] = df["y"].diff(1)          # cambio frente al trimestre anterior
df["delta_4"] = df["y"].diff(4)          # cambio frente al mismo trimestre año anterior
df["growth_yoy"] = df["y"].pct_change(4)
```

13 Técnicas para desestacionalizar

Para datos trimestrales:

$$z_t = y_t - y_{t-4}$$

Tasa interanual:

$$g_t = \frac{y_t}{y_{t-4}} - 1$$

Descomposición STL:

$$y_t = T_t + S_t + R_t$$

donde T es tendencia, S estacionalidad y R residuo.

14 Contraste U de Mann–Whitney

Mann–Whitney es un contraste no paramétrico basado en rangos para comparar dos grupos independientes.

Resultado del ejercicio:

Métrica	Mediana pre	Mediana post	Dif. relativa	U	p aprox	Rank-bis.
GGR / cuenta activa	201,26 €	242,78 €	+20,63%	101	0,0001	0,67
Depósitos / cuenta	491,73 €	782,48 €	+59,13%	0	<0,0001	1,00

```
from scipy import stats
```

```
u_stat, p_value = stats.mannwhitneyu(
    pre["ggr_per_active_account_eur"],
    post["ggr_per_active_account_eur"],
    alternative="two-sided",
)
```

15 Ejecución práctica del proyecto

Desde la raíz, con el entorno virtual activo:

```
python -m src.profile
python -m src.transform
python -m src.validate
python -m src.build_database
python -m pytest -q
python -m nbconvert '
    --to notebook '
    --execute "notebooks/01_responsible_gambling_analysis.ipynb" '
    --output "01_responsible_gambling_analysis_executed.ipynb" '
    --output-dir "notebooks" '
    --ExecutePreprocessor.timeout=300
```

16 Conclusión de la unidad

Este ejercicio muestra que BI, Data Engineering y Data Science no son tres versiones jerárquicas de la misma función. Son perspectivas complementarias sobre una cadena de evidencia:

- **Data Engineering** hace que el dato sea confiable y repetible.
- **BI** convierte ese dato en una métrica comprensible y accionable.
- **Data Science** cuantifica incertidumbre y limita las inferencias.

El salto observado alrededor de 2020-T2 es un caso didáctico especialmente útil porque produce una señal visual y estadística fuerte, pero no autoriza por sí solo una afirmación causal. Esa tensión entre evidencia aparente y conclusión defendible es el aprendizaje central de la unidad.

A Anexo docente: tests unitarios de extracción

A.1 Objetivo

Los ocho tests de `tests/test_extraction.py` introducen el unit testing mediante funciones pequeñas de `src/extract.py`. Se ejecutan sin Internet y con una entrada completamente controlada.

Idea pedagógica central

Un test unitario no demuestra que la web de la DGOJ esté disponible. Demuestra que una unidad interna del extractor responde correctamente ante una entrada conocida.

A.2 CSV utilizado como fixture

Los tests utilizan un CSV mínimo construido en memoria:

```
SAMPLE_CSV = (  
    'Año";"Trimestre";"Mes";"GGR"\n'  
    '2013;"2013.T1";"Enero";1000\n'  
    '2013;"2013.T1";"Febrero";2000\n'  
) .encode("utf-8-sig")
```

La muestra contiene cuatro columnas, dos filas, delimitador de punto y coma y codificación UTF-8 con BOM. Al conocer exactamente la entrada, un fallo puede atribuirse a la función probada y no a una modificación de la fuente externa.

A.3 Descripción de los ocho tests

A.3.1 Detección de HTML

```
def test_looks_like_html_detects_html():  
    assert _looks_like_html(  
        b"<!DOCTYPE html><html><body>error</body></html>"  
    )  
    assert _looks_like_html(b" <html><head></head></html>")
```

Comprueba que una página HTML se identifica correctamente. Evita guardar una página de error, autenticación o bloqueo WAF con extensión CSV.

A.3.2 No confundir un CSV con HTML

```
def test_looks_like_html_rejects_csv():  
    assert not _looks_like_html(SAMPLE_CSV)
```

Valida el caso negativo. Un detector demasiado agresivo también sería un defecto, porque rechazaría datos correctos.

A.3.3 Hash SHA-256 determinista

```
def test_sha256_hex_is_64_hex_chars_and_deterministic():  
    digest = _sha256_hex(SAMPLE_CSV)  
    assert len(digest) == 64  
    assert all(c in "0123456789abcdef" for c in digest)  
    assert digest == _sha256_hex(SAMPLE_CSV)
```

Comprueba que el hash tiene formato hexadecimal válido y que los mismos bytes generan siempre el mismo resultado. El hash permite detectar cambios de contenido, pero no valida su calidad ni su significado.

A.3.4 Nombre publicado en Content-Disposition

```
def test_guess_filename_extracts_from_content_disposition():
    header = (
        'attachment; filename='
        '"JUEGO_ONLINE_2025.T3_GGR_CANT_JUGADAS.csv"'
    )
    assert _guess_filename(header) == (
        "JUEGO_ONLINE_2025.T3_GGR_CANT_JUGADAS.csv"
    )
```

Comprueba que se recupera el nombre remoto desde la cabecera HTTP. Este nombre forma parte de la trazabilidad aunque el proyecto utilice un nombre local canónico.

A.3.5 Cabecera opcional ausente

```
def test_guess_filename_handles_missing_header():
    assert _guess_filename(None) is None
```

Verifica que la ausencia de Content-Disposition se gestiona sin una excepción innecesaria. Una ausencia tolerable no debe tratarse como un error crítico.

A.3.6 Codificación UTF-8 con BOM

```
def test_guess_encoding_reads_utf8_sig():
    assert _guess_encoding(SAMPLE_CSV) in {"utf-8-sig", "utf-8"}
```

Evita errores de decodificación o cabeceras dañadas, por ejemplo `ï»¿Año`. La codificación es parte del contrato técnico del fichero.

A.3.7 Detección del delimitador

```
def test_guess_delimiter_detects_semicolon():
    text = SAMPLE_CSV.decode("utf-8-sig")
    assert _guess_delimiter(text) == ";"
```

Comprueba que se reconoce el punto y coma. Un archivo CSV no tiene por qué emplear una coma como separador.

A.3.8 Inspección de filas, columnas y cabeceras

```
def test_inspect_csv_reports_rows_and_columns():
    result = _inspect_csv(SAMPLE_CSV)
    assert result["rows"] == 2
    assert result["columns"] == 4
    assert result["column_names"] == [
        "Año", "Trimestre", "Mes", "GGR"
    ]
```

Valida los metadatos que se registrarán en el manifiesto. Integra varias funciones puras, pero sigue siendo rápido, determinista y ajeno a la red.

A.4 Cobertura y límites

Los tests cubren	Los tests no cubren
Detección básica de HTML	Disponibilidad real de la DGOJ
SHA-256 determinista	Estabilidad del contenido remoto
Nombre remoto opcional	Todas las variantes de cabeceras HTTP
UTF-8 con BOM	Todas las codificaciones posibles
Delimitador de punto y coma	Cambios semánticos de columnas
Dimensiones y cabeceras	Claves, rangos y cobertura temporal remota

Estos tests no constituyen contract testing. Un contrato vivo debe verificar separadamente los endpoints, el esquema, la cobertura temporal y la política ante cambios.

A.5 Ejecución en clase

```
python -m pytest tests/test_extraction.py -q
```

Resultado esperado:

8 passed

Para mostrar el nombre de cada test:

```
python -m pytest tests/test_extraction.py -v
```

A.6 Actividades sugeridas

1. Anticipar qué test fallaría si el detector de HTML no eliminara espacios iniciales ni normalizara mayúsculas.
2. Añadir casos parametrizados para coma, tabulador, contenido vacío y HTML en mayúsculas.
3. Diseñar un test para `Content-Disposition` sin comillas.
4. Separar los unit tests de un contract test que consulte la fuente real.
5. Diseñar una integración que descargue a una carpeta temporal sin sobrescribir un raw diferente.

B Anexo estadístico: Mann–Whitney, errores y rank-biserial

B.1 Corrección metodológica previa

El rank-biserial no elimina la autocorrelación

Mann–Whitney es un contraste estadístico. El rank-biserial es un tamaño de efecto asociado a ese contraste. Ninguno transforma una serie temporal dependiente en observaciones independientes. La autocorrelación debe tratarse explícitamente mediante técnicas temporales.

B.2 Test U de Mann–Whitney

Mann–Whitney compara los rangos de dos grupos considerados independientes. En el ejercicio se definen antes de observar el resultado:

- **Pre:** 2013-T1 a 2019-T4, 28 trimestres.
- **Transición:** 2020-T1, excluido porque el confinamiento comenzó a mitad del trimestre.
- **Post:** 2020-T2 a 2025-T3, 22 trimestres.

Las hipótesis bilaterales son:

$$H_0 : F_{pre}(x) = F_{post}(x)$$

$$H_1 : F_{pre}(x) \neq F_{post}(x)$$

El test no exige normalidad, pero presupone independencia. Este supuesto es discutible porque un trimestre se parece habitualmente a los trimestres próximos.

B.3 Error tipo I y error tipo II

Realidad	No rechazar H_0	Rechazar H_0
H_0 verdadera	Decisión correcta	Error tipo I: falso positivo
H_0 falsa	Error tipo II: falso negativo	Decisión correcta

B.3.1 Error tipo I

Se concluye que existe una diferencia cuando el proceso no ha cambiado realmente. En este caso sería declarar una ruptura de intensidad cuando el patrón puede explicarse por variación temporal habitual. El nivel α , por ejemplo 0,05, controla esta probabilidad únicamente si se cumplen los supuestos del contraste.

B.3.2 Error tipo II

No se detecta una diferencia que sí existe. Puede ocurrir por una serie corta, alta variabilidad o baja potencia. Si β es la probabilidad de error tipo II, la potencia es:

$$1 - \beta$$

Reducir α disminuye falsos positivos, pero puede aumentar falsos negativos si no crece el tamaño muestral.

B.4 Efecto rank-biserial

El rank-biserial describe la dirección y magnitud de la separación ordinal. Con la convención del notebook:

$$\text{rank_biserial} = 1 - (2 * u_stat) / (n_pre * n_post)$$

- +1: todos los valores post superan a los pre.
- 0: no existe dominancia ordinal clara.
- -1: todos los valores pre superan a los post.

Sin empates relevantes, su lectura probabilística aproximada es:

$$P(\text{post} > \text{pre}) \approx \frac{r_{rb} + 1}{2}$$

Métrica	r_{rb}	Lectura descriptiva
GGR por cuenta activa	0,67	Separación grande; aproximadamente el 83,5% de las comparaciones por pares favorece al periodo post.
Depósitos por cuenta activa	1,00	Separación completa dentro de la muestra observada.

El rank-biserial no debe interpretarse como:

- porcentaje de incremento;
- proporción de varianza explicada;
- probabilidad de que el COVID sea la causa;
- corrección de la autocorrelación;
- contraste estadístico independiente.

B.5 Influencia de la autocorrelación

Mann-Whitney trata los 50 trimestres comparados como observaciones independientes. En una serie temporal normalmente:

$$\text{Corr}(y_t, y_{t-1}) \neq 0$$

Cuando existe autocorrelación positiva, el tamaño muestral efectivo es menor que el número de filas. El p-valor convencional puede resultar demasiado pequeño, los intervalos demasiado estrechos y el error tipo I real mayor que el nominal.

El rank-biserial continúa siendo una descripción válida de la separación observada, pero no resuelve este problema inferencial.

B.6 Métodos apropiados para tratar la dependencia temporal

Descripción prudente

Informar medianas, diferencia absoluta, diferencia relativa, intervalo intercuartílico, rank-biserial y advertencia temporal, sin realizar una afirmación causal.

Permutación por bloques

Reordenar bloques consecutivos en lugar de trimestres individuales para conservar parte de la dependencia interna.

Bootstrap por bloques

Remuestrear bloques mediante moving block, circular block o stationary bootstrap.

Regresión segmentada

Estimar tendencia previa, cambio inmediato de nivel y cambio de pendiente, incorporando errores AR(1) o robustos HAC/Newey–West cuando corresponda.

Ajuste temporal

Retirar tendencia y estacionalidad, analizar residuos y comprobar si mantienen autocorrelación antes de contrastarlos.

Una serie temporal interrumpida básica puede expresarse como:

$$y_t = \beta_0 + \beta_1 \text{tiempo}_t + \beta_2 \text{post}_t + \beta_3 \text{tiempo_post}_t + \varepsilon_t$$

Este modelo distingue tendencia previa, salto de nivel y cambio de pendiente. Aun así, no identifica automáticamente un efecto causal si otros cambios coinciden con 2020-T2.

B.7 Interpretación conjunta recomendada**Redacción defendible**

La mediana del GGR por cuenta activa aumenta de 201,26 € a 242,78 €. Mann–Whitney produce $U = 101$ y $p = 0,0001$, con un efecto rank-biserial de 0,67, lo que indica una separación ordinal grande. No obstante, el p-valor convencional presupone independencia y puede ser optimista por la autocorrelación trimestral. El resultado demuestra una diferencia descriptiva entre periodos, no que el COVID sea su causa.

B.8 Errores de interpretación para debatir

Afirmación	Evaluación
Un rank-biserial de 0,67 significa un incremento del 67%.	Incorrecta
El p-valor demuestra el efecto causal del COVID.	Incorrecta
Mann–Whitney no exige normalidad.	Correcta
Mann–Whitney no necesita independencia.	Incorrecta
El rank-biserial describe separación ordinal.	Correcta
El bootstrap por bloques conserva parte de la dependencia.	Correcta
Un p-valor pequeño garantiza importancia práctica.	Incorrecta

Mensaje final

Mann–Whitney permite detectar separación ordinal y el rank-biserial permite cuantificarla. Para hacer inferencia válida sobre una serie temporal es necesario tratar explícitamente tendencia, estacionalidad y autocorrelación; el tamaño de efecto no sustituye ese trabajo.